

UNIVERSIDAD NACIONAL DE LOJA
Facultad de la Energía, las Industrias y los Recursos Naturales No Renovables
Carrera de Computación

ANTECEDENTES DE INVESTIGACIÓN

Redes Neuronales Recurrentes en el Procesamiento de Datos Secuenciales

Asignatura:

Metodología de la Investigación en Computación

Docente:

Ing. Luis Chamba Eras

Estudiante:

Emilio José Gálvez Merchán

Ciclo:

4to Ciclo

Fecha:

26 de mayo de 2026

Loja – Ecuador

ANTECEDENTES

Las Redes Neuronales Recurrentes (RNN) representan una clase de modelos de aprendizaje profundo fundamentada en conexiones cíclicas que otorgan a la red la capacidad de mantener un estado interno, lo cual las hace teóricamente idóneas para modelar dependencias temporales en datos de naturaleza secuencial. En una revisión crítica de referencia, Lipton, Berkowitz y Elkan [1] sintetizaron tres décadas de investigación sobre estas arquitecturas, concluyendo que los avances en topologías como la Memoria de Corto y Largo Plazo (LSTM) y las redes bidireccionales son los factores determinantes que permitieron su adopción masiva en tareas de predicción de secuencias, análisis de voz y traducción automática. Complementando este panorama, Salehinejad et al. [2] elaboraron una revisión sistemática de los avances recientes en RNN, identificando el problema del gradiente evanescente como el principal obstáculo estructural para el aprendizaje de dependencias a largo plazo, lo que ha impulsado el desarrollo continuo de variantes y estrategias de entrenamiento especializadas.

En el plano de las arquitecturas profundas, Graves, Mohamed e Hinton [3] demostraron que las RNN profundas entrenadas de extremo a extremo con clasificación temporal conexional alcanzaban una tasa de error del 17,7 % en el benchmark TIMIT de reconocimiento fonémico, superando a las redes prealimentadas profundas de la época. Este hallazgo evidenció la ventaja de combinar profundidad arquitectónica con el uso flexible del contexto a larga distancia. Abordando la misma problemática desde un ángulo teórico, Pascanu et al. [4] identificaron tres puntos de profundización en una RNN función de entrada a estado oculto, transición oculto-a-oculto, y función de salida y propusieron dos nuevas topologías profundas que superaron consistentemente a las RNN convencionales en tareas de predicción musical y modelado del lenguaje. A diferencia de los trabajos precedentes que apilaban capas recurrentes de forma homogénea, estas propuestas introdujeron una conceptualización más precisa de qué significa la profundidad en el contexto recurrente.

Un hito metodológico central en la evolución de las RNN fue el desarrollo de mecanismos de compuerta que regulan el flujo de información a través del tiempo. Cho et al. [5] propusieron el modelo Codificador-Decodificador RNN para traducción automática, introduciendo la Unidad Recurrente con Compuertas (GRU) como componente central. Este trabajo demostró que una representación vectorial de longitud fija puede capturar estructura semántica y sintáctica de frases completas, sentando las bases de la arquitectura

seq2seq. En una evaluación empírica posterior, Chung et al. [6] compararon sistemáticamente LSTM, GRU y unidades tanh estándar sobre tareas de modelado de música y señal de voz, concluyendo que ambas unidades con compuertas superan a las unidades recurrentes tradicionales y que la GRU, con menor complejidad paramétrica, ofrece un rendimiento equiparable al de la LSTM en la mayoría de los escenarios evaluados.

El procesamiento de series temporales constituye uno de los dominios de aplicación más activos de las RNN. En una revisión exhaustiva que abarca una década de investigación (2014–2024), Song et al. [7] catalogaron los principales modelos de predicción basados en aprendizaje profundo, destacando la capacidad de las RNN y sus variantes para capturar correlaciones entre pasos temporales y variables multivariadas. Sin embargo, un desafío frecuente en aplicaciones reales es la presencia de valores faltantes, en especial en contextos biomédicos. Che et al. [8] propusieron la arquitectura GRU-D, que incorpora enmascaramiento e intervalos de tiempo como características explícitas dentro de la celda GRU, logrando resultados de vanguardia en los conjuntos clínicos MIMIC-III y PhysioNet. A diferencia de los enfoques de imputación previa a la clasificación, GRU-D explota los propios patrones de ausencia como señal informativa, lo que representa un avance cualitativo en la robustez de las RNN ante datos ruidosos o incompletos.

Las capacidades de modelado secuencial de las RNN han sido aprovechadas en dominios altamente heterogéneos. En el reconocimiento automático del habla, Oruh, Viriri y Adegun [9] propusieron un modelo LSTM-RNN con una compuerta de olvido incorporada que permite procesar flujos continuos de entrada sin incrementar el ancho de banda requerido, alcanzando una precisión del 99,36 % sobre el dataset de dígitos hablados en inglés. En el ámbito del radar, Zhang et al. [10] desarrollaron VGM-RNN, una arquitectura con mitigación explícita del gradiente evanescente orientada a la extrapolación y reconocimiento de secuencias de Perfiles de Rango de Alta Resolución (HRRP), obteniendo mayor precisión y rendimiento anti-ruido que los métodos tradicionales sobre el conjunto MSTAR. En el campo financiero, Zioviris, Kolomvatsos y Stamoulis [11] desarrollaron un esquema híbrido que combina un autoencoder variacional con una LSTM-RNN entrenada sobre conjuntos desequilibrados mediante sobremuestreo, demostrando mejoras sustanciales en recall y precisión frente a métodos de aprendizaje automático convencionales. Adicionalmente, Krok et al. [12] demostraron que las RNN no lineales con predictor de función de base radial pueden aprender patrones de control a partir de datos

operacionales, superando incluso a los controladores analíticos originales en escenarios de control predictivo generalizado.

La implementación de RNN en sistemas con restricciones computacionales ha recibido atención creciente. En el ámbito de las comunicaciones inalámbricas, Di Gennaro et al. [13] propusieron un marco basado en LSTM para resolver el problema de asociación usuario-punto de acceso en sistemas MIMO masivos libres de celda, demostrando escalabilidad sin necesidad de reentrenamiento ante nuevos escenarios de usuario. En la misma línea de sistemas en tiempo real, Holz et al. [14] desarrollaron tres redes neuronales diminutas SPENT, SANT y MANTa de menos de 50 000 parámetros cada una, integradas en un marco de seguimiento multiobjetivo basado en filtro de Kalman, reduciendo el RMSE de predicción en más del 50 % respecto al filtro de Kalman estándar en el benchmark KITTI. En la perspectiva de los sistemas embebidos, Rezk et al. [15] revisaron exhaustivamente las implementaciones de RNN en plataformas de bajo consumo, concluyendo que la reducción del acceso a memoria y las optimizaciones algorítmicas compresión y cuantificación son las vías más prometedoras para lograr eficiencia sin sacrificar precisión. Siebert et al. [16] avanzaron en esta dirección proponiendo un filtro de Kalman mejorado con redes neuronales ligeras para estimación de canal, alcanzando ganancias de hasta 5 dB a bajo SNR con implementación en FPGA de consumo energético 20 veces inferior al equivalente en CPU.

En la frontera del conocimiento actual, varios trabajos abordan limitaciones que persisten en las RNN estándar. Zhang et al. [17] identificaron que las RNN convencionales son incapaces de gestionar desplazamientos de distribución temporal en datos de actividad neural, proponiendo RNN con pesos variables en el tiempo que permiten detectar comportamientos motores hasta seis segundos antes de su inicio, superando en tres segundos a las RNN estándar. Desde la perspectiva del procesamiento simbólico, Honda y Hagiwara [18] demostraron que la combinación de redes de memoria y RNN posibilita la unificación eficiente de datos ambiguos, contribuyendo al desarrollo de sistemas de inferencia con interfaces humano-computador. Para el escenario de series temporales en flujo continuo con deriva conceptual, Giannini, Ziffer y Della Valle [19] propusieron DYNcPNN, una red neuronal progresiva dinámica que supera consistentemente a modelos LSTM continuamente entrenados, evitando el olvido catastrófico mediante expansión controlada de la arquitectura. A diferencia de los enfoques recurrentes, Frazzetto et al. [20] abordaron el problema de la coincidencia secuencial candidato-trabajo mediante Redes

Neuronales de Grafos (GNN), logrando una precisión equilibrada del 65,4 % frente al 55,0 % del perceptrón multicapa; este contraste ilustra cómo las arquitecturas basadas en grafos pueden ser más adecuadas cuando la estructura relacional entre entidades prima sobre la dependencia temporal estricta.

Brecha de Investigación

El análisis del conjunto de trabajos revisados revela que, si bien la literatura acumulada sobre RNN es extensa y abarca aplicaciones en voz [3], [9], radar [10], finanzas [11], control [12], comunicaciones [13], seguimiento [14] y neurociencia [17], cada propuesta resuelve una limitación puntual sin ofrecer un marco comparativo unificado. Las revisiones existentes [1], [2], [7] proporcionan una visión panorámica valiosa, pero no evalúan de forma sistemática qué variantes arquitectónicas LSTM, GRU [5], [6], RNN profundas [3], [4], GRU-D [8] son más efectivas en función del tipo y la naturaleza de la secuencia. Asimismo, los avances en eficiencia computacional [15], [16] y en manejo de no estacionariedad [17], [19] no han sido integrados en una perspectiva holística que considere simultáneamente el rendimiento predictivo, la viabilidad de implementación y la robustez ante condiciones adversas de los datos. La presente investigación se orienta a cubrir esta brecha, caracterizando de forma integral el papel de las RNN en el procesamiento de datos secuenciales y contribuyendo a una comprensión más sistemática y generalizable de sus potencialidades y limitaciones en escenarios de alta heterogeneidad estructural.

Referencias

- [1] Z. C. Lipton, J. Berkowitz y C. Elkan, "A Critical Review of Recurrent Neural Networks for Sequence Learning," *arXiv:1506.00019*, 2015.
- [2] H. Salehinejad *et al.*, "Recent Advances in Recurrent Neural Networks," *arXiv:1801.01078*, 2018.
- [3] A. Graves, A. Mohamed y G. Hinton, "Speech Recognition with Deep Recurrent Neural Networks," *arXiv:1303.5778*, 2013.
- [4] R. Pascanu, C. Gulcehre, K. Cho y Y. Bengio, "How to Construct Deep Recurrent Neural Networks," *arXiv:1312.6026*, 2014.

- [5] K. Cho *et al.*, "Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation," *arXiv:1406.1078*, 2014.
- [6] J. Chung, C. Gulcehre, K. Cho y Y. Bengio, "Empirical Evaluation of Gated Recurrent Neural Networks on Sequence Modeling," *arXiv:1412.3555*, 2014.
- [7] X. Song *et al.*, "Deep learning-based time series forecasting," *Artificial Intelligence Review*, vol. 58, no. 1, 2025, doi: 10.1007/s10462-024-10989-8.
- [8] Z. Che, S. Purushotham, K. Cho, D. Sontag y Y. Liu, "Recurrent Neural Networks for Multivariate Time Series with Missing Values," *Scientific Reports*, vol. 8, no. 1, 2018, doi: 10.1038/s41598-018-24271-9.
- [9] J. Oruh, S. Viriri y A. Adegun, "Long Short-Term Memory Recurrent Neural Network for Automatic Speech Recognition," *IEEE Access*, vol. 10, pp. 30069–30079, 2022, doi: 10.1109/ACCESS.2022.3159339.
- [10] Y. Zhang, F. Xiao, F. Qian y X. Li, "VGM-RNN: HRRP Sequence Extrapolation and Recognition Based on a Novel Optimized RNN," *IEEE Access*, vol. 8, pp. 70071–70081, 2020, doi: 10.1109/ACCESS.2020.2986027.
- [11] G. Zioviris, K. Kolomvatsos y G. Stamoulis, "An intelligent sequential fraud detection model based on deep learning," *Journal of Supercomputing*, vol. 80, no. 10, pp. 14824–14847, 2024, doi: 10.1007/s11227-024-06030-y.
- [12] M. Krok *et al.*, "Application of feedforward and recurrent neural networks for model-based control systems," *Control Theory and Technology*, vol. 23, no. 1, pp. 91–104, 2025, doi: 10.1007/s11768-024-00234-6.
- [13] G. Di Gennaro *et al.*, "A General Framework for Scalable UE-AP Association in User-Centric Cell-Free Massive MIMO Based on Recurrent Neural Networks," in *Proc. IEEE SPAWC*, pp. 661–665, 2024, doi: 10.1109/SPAWC60668.2024.10694529.
- [14] C. Holz *et al.*, "Tiny neural networks for multi-object tracking in a modular Kalman framework," *Autonomous Intelligent Systems*, vol. 6, no. 1, 2026, doi: 10.1007/s43684-026-00127-2.

- [15] N. M. Rezk, M. Purnaprajna, T. Nordstrom y Z. Ul-Abdin, "Recurrent Neural Networks: An Embedded Computing Perspective," *IEEE Access*, vol. 8, pp. 57967–57996, 2020, doi: 10.1109/ACCESS.2020.2982416.
- [16] A. Siebert *et al.*, "Low-complexity and low-energy RNN-enhanced Kalman filter for Channel Estimation: A case study," *IEEE Open Journal of the Communications Society*, 2026, doi: 10.1109/OJCOMS.2026.3665311.
- [17] Y. Zhang *et al.*, "Behavioral Classification of Sequential Neural Activity Using Time Varying Recurrent Neural Networks," *IEEE Trans. Neural Syst. Rehabil. Eng.*, vol. 33, pp. 2638–2649, 2025, doi: 10.1109/TNSRE.2025.3586175.
- [18] H. Honda y M. Hagiwara, "Efficient deep neural unification in symbolic processing," *Neural Computing and Applications*, vol. 37, no. 27, pp. 22827–22855, 2025, doi: 10.1007/s00521-025-11512-y.
- [19] F. Giannini, G. Ziffer y E. Della Valle, "Dynamic continuous progressive neural networks for evolving streaming time series," *Data Mining and Knowledge Discovery*, vol. 40, no. 4, p. 49, 2026, doi: 10.1007/s10618-026-01213-y.
- [20] P. Frazzetto *et al.*, "Graph Neural Networks for Candidate-Job Matching: An Inductive Learning Approach," *Data Science and Engineering*, 2025, doi: 10.1007/s41019-025-00293-y.