

**Universidad Nacional de Loja**

**RNN y Modelos de Visión.**

**AUTOR: Emilio Jose Galvez Merchan**

**2026**

## Declaración de Uso de Inteligencia Artificial Generativa

El autor declara que para el desarrollo de la presente investigación se han utilizado herramientas de Inteligencia Artificial (IA) generativa y tecnologías de asistencia lingüística bajo un marco de integridad académica y ética profesional.

### Herramientas utilizadas

- **NotebookLM (Google):** Utilizado para la síntesis de documentos técnicos, análisis de coherencia entre fuentes bibliográficas y extracción de conceptos clave de la literatura seleccionada.
- **ChatGPT / Gemini:** Empleados para la asistencia en la depuración de código fuente (LaTeX/Python), estructuración gramatical de párrafos y traducción técnica de términos científicos.
- **DeepL / Grammarly:** Utilizados para la revisión ortotipográfica y la mejora de la fluidez narrativa en la redacción del documento.

### Responsabilidad del autor

El autor asume la responsabilidad total por el contenido final de este trabajo. El uso de las herramientas mencionadas se limitó a la optimización de procesos de redacción y análisis de datos, garantizando que todas las conclusiones y el desarrollo intelectual son producto del criterio crítico del investigador.

# Índice General

|                                                                 |          |
|-----------------------------------------------------------------|----------|
| <b>Declaración de Uso de Inteligencia Artificial Generativa</b> | <b>1</b> |
| <b>1 Introducción</b>                                           | <b>4</b> |
| <b>2 Metodología</b>                                            | <b>5</b> |
| 2.1 Área de estudio . . . . .                                   | 5        |
| 2.2 Priorización Bibliográfica . . . . .                        | 5        |
| 2.3 Tabla de Priorización Bibliográfica . . . . .               | 5        |
| <b>Referencias bibliográficas</b>                               | <b>8</b> |

# Índice de Tablas

|     |                                                                      |   |
|-----|----------------------------------------------------------------------|---|
| 2.1 | Clasificación de Preguntas de Investigación . . . . .                | 5 |
| 2.2 | Clasificación y Priorización de la Literatura Seleccionada . . . . . | 5 |

## 1. Introducción

Este trabajo integra el uso de NotebookLM para la síntesis bibliográfica y modelos recurrentes.

## 2. Metodología

### 2.1. Área de estudio

La investigación se centra en el despliegue de modelos de IA en el borde.

Tabla 2.1: Clasificación de Preguntas de Investigación

| Tipo de Pregunta | Propuesta de Pregunta                                   |
|------------------|---------------------------------------------------------|
| Exploratoria     | ¿Desafíos técnicos de las RNN en dispositivos de borde? |
| Descriptiva      | ¿Eficiencia espectral en redes 6G usando BiLSTM?        |

### 2.2. Priorización Bibliográfica

En esta sección se detallan las fuentes seleccionadas y su nivel de relevancia para el proyecto.

### 2.3. Tabla de Priorización Bibliográfica

Tabla 2.2: Clasificación y Priorización de la Literatura Seleccionada

| Clasificación | Referencia | Prioridad | Justificación                                                                  |
|---------------|------------|-----------|--------------------------------------------------------------------------------|
| Antecedentes  | [1]        | Alta      | Documento fundacional sobre RNN profundas y LSTM para voz.                     |
|               | [2]        | Alta      | Análisis teórico de la profundidad estructural en las transiciones de las RNN. |
|               | [3]        | Alta      | Introducción del modelo Encoder-Decoder y la arquitectura GRU.                 |

Tabla 2.2 – Continuación

| Clasificación   | Referencia | Prioridad | Justificación                                                              |
|-----------------|------------|-----------|----------------------------------------------------------------------------|
|                 | [4]        | Alta      | Revisión crítica que sintetiza décadas de aprendizaje secuencial.          |
|                 | [5]        | Alta      | Comparativa técnica que valida los mecanismos de puertas (gating).         |
|                 | [6]        | Media     | Panorama técnico de la evolución previa a los Transformers.                |
|                 | [7]        | Media     | Uso de GRU-D para gestionar valores faltantes en series médicas.           |
|                 | [8]        | Media     | Mitigación del gradiente desvanecido en señales de radar (VGM-RNN).        |
|                 | [9]        | Baja      | Optimización de hardware para ejecución de RNN en móviles.                 |
|                 | [10]       | Baja      | Aplicación de LSTM estándar en reconocimiento de voz digital.              |
| Estado del Arte | [11]       | Alta      | Revisión que posiciona a las RNN frente a competidores como Transformers.  |
|                 | [12]       | Alta      | Innovación en pesos variables (TV-RNN) para datos biológicos cambiantes.   |
|                 | [13]       | Alta      | Propuesta para evitar el olvido catastrófico en flujos de datos (DYNcPNN). |
|                 | [14]       | Media     | Escalabilidad de BiLSTM en infraestructuras de comunicaciones 6G.          |
|                 | [15]       | Media     | Hibridación de Filtro de Kalman con RNN para eficiencia energética.        |
|                 | [16]       | Media     | Integración de lógica simbólica con memorias neuronales.                   |
|                 | [17]       | Media     | Detección de fraude financiero mediante Autoencoders y LSTM.               |
|                 | [18]       | Baja      | Uso de RNN en sistemas de control predictivo industrial.                   |
|                 | [19]       | Baja      | Tiny RNN para seguimiento de objetos en tiempo real.                       |

**Tabla 2.2 – Continuación**

| Clasificación        | Referencia           | Prioridad | Justificación                                             |
|----------------------|----------------------|-----------|-----------------------------------------------------------|
| <b>Trabajos Rel.</b> | <a href="#">[20]</a> | Media     | Evidencia del valor de GNN frente a modelos secuenciales. |

## Referencias bibliográficas

- [1] A. Graves, A. rahman Mohamed, and G. Hinton, “Speech recognition with deep recurrent neural networks,” 3 2013. [Online]. Available: <http://arxiv.org/abs/1303.5778>
- [2] R. Pascanu, C. Gulcehre, K. Cho, and Y. Bengio, “How to construct deep recurrent neural networks,” 4 2014. [Online]. Available: <http://arxiv.org/abs/1312.6026>
- [3] K. Cho, B. van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, and Y. Bengio, “Learning phrase representations using rnn encoder-decoder for statistical machine translation,” 9 2014. [Online]. Available: <http://arxiv.org/abs/1406.1078>
- [4] Z. C. Lipton, J. Berkowitz, and C. Elkan, “A critical review of recurrent neural networks for sequence learning,” 10 2015. [Online]. Available: <http://arxiv.org/abs/1506.00019>
- [5] J. Chung, C. Gulcehre, K. Cho, and Y. Bengio, “Empirical evaluation of gated recurrent neural networks on sequence modeling,” 12 2014. [Online]. Available: <http://arxiv.org/abs/1412.3555>
- [6] H. Salehinejad, S. Sankar, J. Barfett, E. Colak, and S. Valaee, “Recent advances in recurrent neural networks,” 2 2018. [Online]. Available: <http://arxiv.org/abs/1801.01078>
- [7] Z. Che, S. Purushotham, K. Cho, D. Sontag, and Y. Liu, “Recurrent neural networks for multivariate time series with missing values,” *Scientific Reports*, vol. 8, 12 2018.
- [8] Y. Zhang, F. Xiao, F. Qian, and X. Li, “Vgm-rnn: Hrrp sequence extrapolation and recognition based on a novel optimized rnn,” *IEEE Access*, vol. 8, pp. 70 071–70 081, 2020.
- [9] N. M. Rezk, M. Purnaprajna, T. Nordstrom, and Z. Ul-Abdin, “Recurrent neural networks: An embedded computing perspective,” pp. 57 967–57 996, 2020.

- [10] J. Oruh, S. Viriri, and A. Adegun, “Long short-term memory recurrent neural network for automatic speech recognition,” *IEEE Access*, vol. 10, pp. 30 069–30 079, 2022.
- [11] X. Song, L. Deng, H. Wang, Y. Zhang, Y. He, and W. Cao, “Deep learning-based time series forecasting,” *Artificial Intelligence Review*, vol. 58, 1 2025.
- [12] Y. Zhang, C. Mitelut, D. J. Arpin, D. Vaillancourt, T. Murphy, and S. Saxena, “Behavioral classification of sequential neural activity using time varying recurrent neural networks,” *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 33, pp. 2638–2649, 2025.
- [13] F. Giannini, G. Ziffer, and E. D. Valle, “Dynamic continuous progressive neural networks for evolving streaming time series,” *Data Mining and Knowledge Discovery*, vol. 40, p. 49, 8 2026. [Online]. Available: <https://link.springer.com/10.1007/s10618-026-01213-y>
- [14] G. D. Gennaro, A. Buonanno, G. Romano, S. Buzzi, and F. A. Palmieri, “A general framework for scalable ue-ap association in user-centric cell-free massive mimo based on recurrent neural networks,” in *IEEE Workshop on Signal Processing Advances in Wireless Communications, SPAWC*. Institute of Electrical and Electronics Engineers Inc., 2024, pp. 661–665.
- [15] A. Siebert, B. L. Gal, G. Ferre, and A. Fourny, “Low-complexity and low-energy rnn-enhanced kalman filter for channel estimation: A case study,” *IEEE Open Journal of the Communications Society*, 2026.
- [16] H. Honda and M. Hagiwara, “Efficient deep neural unification in symbolic processing,” *Neural Computing and Applications*, vol. 37, pp. 22 827–22 855, 9 2025.
- [17] G. Zioviris, K. Kolomvatsos, and G. Stamoulis, “An intelligent sequential fraud detection model based on deep learning,” *Journal of Supercomputing*, vol. 80, pp. 14 824–14 847, 7 2024.
- [18] M. Krok, W. P. Hunek, S. Mielczarek, F. Buchwald, and A. Kolender, “Application of feedforward and recurrent neural networks for model-based control systems,” *Control Theory and Technology*, vol. 23, pp. 91–104, 2 2025.
- [19] C. Holz, C. Bader, M. Enzweiler, and M. Drüppel, “Tiny neural networks for multi-object tracking in a modular kalman framework,” *Autonomous Intelligent Systems*, vol. 6, 12 2026.

- [20] P. Frazzetto, M. U. U. Haq, F. Fabris, and A. Sperduti, “Graph neural networks for candidate-job matching: An inductive learning approach,” *Data Science and Engineering*, 2025.