

Fundamentos de Inteligencia Artificial Clásica: Técnicas, Métodos y Aplicaciones Antes de la IA Generativa

Luis Chamba-Eras

Editor

2026

Índice general

I	Introducción y Fundamentos	1
II	Aprendizaje Estadístico y Modelos de Clasificación	2
1.	Modelado de la Incertidumbre en Sistemas de Diagnóstico Médico mediante Redes Bayesianas	3
1.1.	Introducción	3
1.2.	Fundamentos Teóricos	3
1.3.	Metodología y Análisis de la Literatura	3
1.4.	Conclusiones	4
2.	Procesamiento de Datos Secuenciales mediante Redes Neuronales Recurrentes	5
2.1.	Introducción	5
2.2.	Fundamentos Teóricos	5
2.3.	Metodología y Análisis de la Literatura	6
2.4.	Conclusiones	7

Parte I

Introducción y Fundamentos

Parte II

Aprendizaje Estadístico y Modelos de Clasificación

Capítulo 1

Modelado de la Incertidumbre en Sistemas de Diagnóstico Médico mediante Redes Bayesianas

Autor: Miguel Alejandro Armas Ordoñez

Técnica asignada: Redes Bayesianas

1.1. Introducción

Este capítulo aborda formalmente el uso de los modelos probabilísticos gráficos para dar respuesta a la pregunta de investigación planteada: ¿Cómo se utilizan las redes bayesianas para modelar la incertidumbre en sistemas de diagnóstico médico? [1].

1.2. Fundamentos Teóricos

Una red bayesiana calcula la distribución de probabilidad conjunta mediante la factorización de dependencias condicionales estructuradas en un grafo acíclico dirigido, expresada matemáticamente en la Ecuación 1.1:

$$P(X_1, X_2, \dots, X_n) = \prod_{i=1}^n P(X_i \mid \text{Padres}(X_i)) \quad (1.1)$$

1.3. Metodología y Análisis de la Literatura

A través de la metodología de jerarquización científica y la extracción de datos de artículos indexados en bases de datos de alto impacto [2], se estructuraron las dimensiones de rendimiento técnico explicadas en la Tabla 1.1.

Tabla 1.1: Dimensiones de análisis en redes probabilísticas clínicas.

Parámetro	Ventaja Tecnológica	Restricción
Cómputo	Consumo mínimo de memoria RAM	Complejidad algorítmica NP-Hard
Explicabilidad	Trazabilidad analítica exacta	Dependencia de expertos de dominio

1.4. Conclusiones

Las técnicas analíticas clásicas analizadas en este volumen proveen una base de explicabilidad matemática robusta, la cual es crucial para auditar las soluciones automatizadas modernas en la ingeniería de software actual.

Capítulo 2

Procesamiento de Datos Secuenciales mediante Redes Neuronales Recurrentes

Autor: Emilio José Gálvez Merchán

Técnica asignada: Redes Neuronales Recurrentes (RNN)

2.1. Introducción

El procesamiento de datos secuenciales representa uno de los desafíos más complejos en la computación contemporánea, debido a que las redes neuronales estándar de paso hacia adelante (*feedforward*) operan bajo la asunción de independencia entre los ejemplos de entrenamiento, perdiendo el estado de la red tras procesar cada punto de datos [3]. En entornos donde los datos están relacionados en el tiempo o el espacio —como fragmentos de audio, palabras en oraciones o tramas de video—, esta asunción de independencia resulta inaceptable [3, 4]. Las Redes Neuronales Recurrentes (RNN) surgen como modelos conexionistas capaces de capturar dinámicas secuenciales mediante ciclos de retroalimentación en su arquitectura, permitiendo que la información persista a través de los pasos de la secuencia [3, 4]. El papel fundamental de las RNN es actuar como un sistema de memoria que retiene un estado interno capaz de representar información de una ventana de contexto arbitrariamente larga, rompiendo la restricción de dimensiones fijas en las entradas y salidas [3–5].

En la práctica, este papel se traduce en aplicaciones de vanguardia que van más allá del modelado de lenguaje. En el ámbito de la defensa y vigilancia, las RNN permiten la extrapolación de muestras perdidas en secuencias de radar de alta resolución (HRRP), utilizando la correlación espaciotemporal para reparar señales ruidosas [6]. En la neurociencia computacional, variantes avanzadas permiten la clasificación prematura de actividad neural para decodificar comportamientos motores en pacientes con enfermedades neurodegenerativas [7]. Asimismo, su integración en sistemas híbridos, como la combinación de filtros de Kalman con unidades recurrentes (GRU), ha revolucionado la estimación de canales en radiocomunicaciones, permitiendo un seguimiento adaptativo y eficiente del estado del canal en tiempo real [8].

2.2. Fundamentos Teóricos

Matemáticamente, una RNN simula un sistema dinámico de tiempo discreto donde el estado oculto en un instante dado es una función de todos los estados previos [4, 9]. Dado una secuencia de entrada $\mathbf{x} = (x_1, x_2, \dots, x_T)$, la red actualiza recursivamente un vector de estado oculto h_t

que sirve como la “memoria” del sistema [5, 10]. El cálculo del paso hacia adelante (*forward pass*) clásico para actualizar el estado oculto h_t se define mediante la siguiente ecuación fundamental:

$$h_t = H(W_{xh}x_t + W_{hh}h_{t-1} + b_h) \quad (2.1)$$

Donde W_{xh} es la matriz de pesos entre la entrada y la capa oculta, W_{hh} es la matriz de pesos recurrentes que conecta el estado previo con el actual, b_h es el vector de sesgo, y H es una función de activación no lineal, generalmente una sigmoide o una tangente hiperbólica ($\tanh$) [4, 5, 11]. La salida de la red en el tiempo t , denotada como y_t , se calcula a partir del estado oculto actual:

$$y_t = W_{hy}h_t + b_y \quad (2.2)$$

Esta estructura permite que una entrada en el tiempo $t - 1$ influya en la salida en el tiempo t y pasos posteriores, facilitando el aprendizaje de dependencias temporales complejas [3, 4]. El entrenamiento de estos parámetros se realiza típicamente mediante el algoritmo de retropropagación a través del tiempo (BPTT), el cual despliega la red en una estructura de capas idénticas para aplicar el descenso de gradiente [4].

2.3. Metodología y Análisis de la Literatura

El análisis de la literatura técnica revela que la implementación de RNN enfrenta un compromiso constante entre la capacidad de modelado y las restricciones de los sistemas computacionales físicos. La Tabla 2.1 sintetiza las dimensiones de rendimiento técnico identificadas en las fuentes de la literatura consultada [3, 4, 6–8].

Tabla 2.1: Dimensiones de rendimiento técnico en arquitecturas recurrentes.

Parámetro	Ventaja Tecnológica	Restricción / Limitación
Cómputo y Memoria (Dependencias)	Capacidad teórica para capturar dependencias de largo alcance y representar sistemas dinámicos no lineales complejos que modelos de Markov no pueden procesar [3, 4].	Susceptibilidad crítica a la inestabilidad de gradientes (desvanecimiento y explosión), lo que limita la memoria práctica a pasos temporales recientes en RNN clásicas [4, 11].
Eficiencia de Despliegue en Hardware	Viabilidad de procesamiento en tiempo real en dispositivos de borde (<i>edge</i>) para tareas de voz y audio mediante optimizaciones como cuantización y poda [4, 8].	Alta demanda de ancho de banda de memoria y operaciones MAC; el consumo energético en CPUs convencionales puede ser hasta 20 veces mayor que en FPGAs optimizadas [4, 8].
Explicabilidad	Capacidad de modelar comportamientos biológicos y físicos de forma granular, permitiendo el uso de valores SHAP para interpretar decisiones neuronales [7, 8].	Naturaleza predominante de “caja negra” en modelos profundos; los sistemas militares y médicos exigen una trazabilidad que las RNN puras a menudo no satisfacen sin componentes deterministas adicionales [7, 8].

2.4. Conclusiones

El papel de las RNN en el procesamiento de datos secuenciales ha evolucionado de un marco teórico a una herramienta de ingeniería de software indispensable para sistemas con conciencia del contexto. La técnica clásica ha superado sus limitaciones intrínsecas —específicamente el problema del gradiente desvanecido— mediante la evolución hacia arquitecturas con mecanismos de compuertas, como las unidades de Memoria a Largo Corto Plazo (LSTM) y las Unidades Recurrentes Calibradas (GRU), que permiten un control adaptativo sobre qué información recordar u olvidar [4, 11]. Asimismo, la introducción de arquitecturas apiladas (*deep RNNs*) y esquemas de codificador-decodificador (*Encoder-Decoder*) ha permitido el mapeo exitoso de secuencias de longitudes variables, fundamental en la traducción automática y el reconocimiento del habla [5, 9, 10]. En la actualidad, la relevancia de las RNN reside en su capacidad de integrarse en infraestructuras de borde y sistemas masivos como las redes 6G (MIMO sin celdas), donde su escalabilidad y robustez frente a datos incompletos aseguran la viabilidad de soluciones inteligentes y automatizadas en entornos con recursos limitados [4, 12].

Referencias

- [1] M. A. Armas Ordoñez, “Modelado probabilístico estructurado en la informática médica e ingeniería clínica,” *IEEE Transactions on Artificial Intelligence*, vol. 6, no. 2, pp. 112–125, 2025.
- [2] L. Chamba-Eras, *Metodología de la Investigación en Computación: Una Guía para el Diseño de Sistemas Inteligentes*. Loja, Ecuador: Editorial Universidad Nacional de Loja, 2026.
- [3] Z. C. Lipton, J. Berkowitz, and C. Elkan, “A critical review of recurrent neural networks for sequence learning,” 10 2015.
- [4] N. M. Rezk, M. Purnaprajna, T. Nordstrom, and Z. Ul-Abdin, “Recurrent neural networks: An embedded computing perspective,” 2020.
- [5] A. Graves, A. rahman Mohamed, and G. Hinton, “Speech recognition with deep recurrent neural networks,” 3 2013.
- [6] Y. Zhang, F. Xiao, F. Qian, and X. Li, “Vgm-rnn: Hrrp sequence extrapolation and recognition based on a novel optimized rnn,” *IEEE Access*, vol. 8, pp. 70071–70081, 2020.
- [7] Y. Zhang, C. Mitelut, D. J. Arpin, D. Vaillancourt, T. Murphy, and S. Saxena, “Behavioral classification of sequential neural activity using time varying recurrent neural networks,” *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 33, pp. 2638–2649, 2025.
- [8] A. Siebert, B. L. Gal, G. Ferre, and A. Fourny, “Low-complexity and low-energy rnn-enhanced kalman filter for channel estimation: A case study,” *IEEE Open Journal of the Communications Society*, 2026.
- [9] R. Pascanu, C. Gulcehre, K. Cho, and Y. Bengio, “How to construct deep recurrent neural networks,” 4 2014.
- [10] K. Cho, B. van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, and Y. Bengio, “Learning phrase representations using rnn encoder-decoder for statistical machine translation,” 9 2014.
- [11] J. Chung, C. Gulcehre, K. Cho, and Y. Bengio, “Empirical evaluation of gated recurrent neural networks on sequence modeling,” 12 2014.
- [12] G. D. Gennaro, A. Buonanno, G. Romano, S. Buzzi, and F. A. Palmieri, “A general framework for scalable ue-ap association in user-centric cell-free massive mimo based on recurrent neural networks,” in *IEEE Workshop on Signal Processing Advances in Wireless Communications, SPAWC*, pp. 661–665, Institute of Electrical and Electronics Engineers Inc., 2024.