

Información general del estudiante (ejemplo)

- **Nombre del estudiante:** Emilio José Galvez Merchán
- **Técnica de IA:** Redes Red Neuronal Recurrente (RNN)
- **Pregunta de investigación:** ¿Qué papel juegan las RNN en el procesamiento de datos secuenciales?

Descripción del Problema Técnico

1. Contexto general del problema

En el ámbito de los Sistemas Inteligentes y el Procesamiento de Señales, el tratamiento de datos secuenciales es una necesidad crítica para el desarrollo de infraestructuras tecnológicas avanzadas, tales como las redes de comunicaciones móviles 6G, el monitoreo biomédico de actividad neuronal y los sistemas de vigilancia por radar para la defensa [1],[2],[3],[4],[5]. Estos entornos exigen la interpretación precisa de señales temporales distribuidas espacialmente para permitir una toma de decisiones automatizada y eficiente en tiempo real [1],[2].

2. Situación actual basada en evidencia

Las Redes Neuronales Recurrentes (RNN) se han consolidado como la herramienta estándar para modelar secuencias debido a su capacidad de retener memoria de entradas pasadas mediante estados ocultos [2],[5]. Sin embargo, la literatura técnica señala que modelos tradicionales como los Modelos Ocultos de Markov (HMM) presentan una elevada complejidad computacional y una capacidad insuficiente para procesar secuencias de alta dimensión o gran longitud [4]. Por otro lado, los clasificadores independientes (como SVM aplicados en ventanas) no logran capturar adecuadamente la información temporal oculta en las series de datos al no existir conexión entre ellos [2].

3. Brecha o vacío identificado

A pesar de los avances en el aprendizaje profundo, persiste una brecha significativa en la capacidad de los modelos para adaptarse de forma robusta ante cambios en la distribución temporal de los datos (*temporal distributional shifts*) [2]. Asimismo, existe una deficiencia técnica en los métodos para extrapolar y reparar muestras perdidas en secuencias ruidosas e incompletas, sumada a una falta de interpretabilidad en las arquitecturas convencionales de "caja negra" que dificulta su adopción en sistemas de misión crítica o militares donde la trazabilidad de las decisiones es esencial [3],[4]. Adicionalmente, la ejecución de RNN en dispositivos de borde (*edge devices*) se ve severamente limitada por la alta demanda de capacidad de cómputo y el espacio de memoria requerido [5].

4. Problema central

El problema radica en la intratabilidad computacional y la degradación del rendimiento de los modelos de aprendizaje secuencial cuando se enfrentan a datos masivos, ruidosos o fragmentados en entornos de recursos limitados, lo que impide realizar clasificaciones tempranas, precisas y eficientes que sean viables para su despliegue en sistemas distribuidos y plataformas embebidas [1],[3],[4],[5].

5. Consecuencias o impacto

Esta situación genera consecuencias negativas como la ineficiencia espectral en redes móviles debido a asociaciones subóptimas entre usuarios y antenas [1]. En el ámbito médico, el retraso en la detección de comportamientos neuronales impide intervenciones correctivas oportunas para enfermedades como el Parkinson. Además, se producen fallos críticos en el reconocimiento automático de objetivos (RATR) por radar y un consumo energético excesivo que limita la viabilidad técnica de soluciones inteligentes en hardware embebido de baja potencia [3],[4].

6. Actores involucrados

Los principales actores afectados incluyen a los operadores de telecomunicaciones que despliegan infraestructuras 6G, investigadores clínicos y pacientes que requieren sistemas de neuromodulación de bucle cerrado, organizaciones de defensa que dependen de la precisión de sus sensores, y desarrolladores de hardware que buscan optimizar el despliegue de IA en el borde [1],[2],[4],[5].

7. Variables o elementos clave

Las variables técnicas centrales asociadas al problema incluyen:

- **Desplazamientos de distribución temporal:** Variaciones en las propiedades estadísticas de la señal a lo largo del tiempo [2].
- **Gradiente desvaneciente y explosivo:** Fenómeno que dificulta el aprendizaje de dependencias de largo plazo en secuencias extensas [4],[5].
- **Complejidad de cómputo y memoria:** Medida en GOP/s y huella de almacenamiento necesaria para el modelo [3],[5].
- **Correlación espaciotemporal:** Capacidad de capturar dependencias entre muestras adyacentes y sensores distribuidos [1],[4].

8. Delimitación del problema

La investigación se delimita al diseño y optimización de arquitecturas RNN y sus variantes avanzadas (BiLSTM, TV-RNN, GRU y VGM-RNN) para el procesamiento de datos secuenciales en tiempo real [1],[2],[3],[4]. Se excluyen los modelos de aprendizaje supervisado puramente estáticos que no incorporan mecanismos de retroalimentación temporal o memoria interna persistente [2],[5].

9. Vinculación con la sublínea de investigación

Este problema se vincula directamente con las sublíneas de Inteligencia Artificial y Procesamiento de Señales, dado su enfoque en la mejora de la estabilidad del entrenamiento mediante la mitigación del gradiente desvanecido, la reducción de la complejidad algorítmica a través de la cuantización/compresión y la creación de modelos híbridos que aumentan la interpretabilidad en sistemas de comunicación y defensa [2],[4],[5].

Bibliografía

- [1] G. Di Gennaro, A. Buonanno, G. Romano, S. Buzzi, and F. A. N. Palmieri, “A Deep Learning Approach for User-Centric Clustering in Cell-Free Massive MIMO Systems,” in *IEEE Workshop on Signal Processing Advances in Wireless Communications, SPAWC*, Institute of Electrical and Electronics Engineers Inc., 2024, pp. 661–665. doi: 10.1109/SPAWC60668.2024.10694529.
- [2] Y. Zhang, C. Mitelut, D. J. Arpin, D. Vaillancourt, T. Murphy, and S. Saxena, “Behavioral Classification of Sequential Neural Activity Using Time Varying Recurrent Neural Networks,” *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 33, pp. 2638–2649, 2025, doi: 10.1109/TNSRE.2025.3586175.
- [3] A. Siebert, B. Le Gal, G. Ferre, and A. Fourny, “Low-complexity and low-energy RNN-enhanced Kalman filter for Channel Estimation: A case study,” *IEEE Open Journal of the Communications Society*, 2026, doi: 10.1109/OJCOMS.2026.3665311.
- [4] N. M. Rezk, M. Purnaprajna, T. Nordstrom, and Z. Ul-Abdin, “Recurrent Neural Networks: An Embedded Computing Perspective,” 2020, *Institute of Electrical and Electronics Engineers Inc.* doi: 10.1109/ACCESS.2020.2982416.
- [5] Y. Zhang, F. Xiao, F. Qian, and X. Li, “VGM-RNN: HRRP Sequence Extrapolation and Recognition Based on a Novel Optimized RNN,” *IEEE Access*, vol. 8, pp. 70071–70081, 2020, doi: 10.1109/ACCESS.2020.2986027.