

Información General del Estudiante

Nombre del estudiante: Emilio José Galvez Merchán

Técnica de IA: Redes Neuronal Recurrente (RNN)

Pregunta de investigación: ¿Qué papel juegan las RNN en el procesamiento de datos secuenciales?

Matriz de Extracción: El papel de las RNN en el procesamiento de datos secuenciales

Trabajo (Ref.)	Enfoque Cuantitativo	Enfoque Cualitativo	Enfoque Mixto	Observación
Graves et al. (2013)	Logra un error del 17.7% en el benchmark TIMIT usando LSTM profundas.	No se encontró información en los documentos sobre este punto.	No se encontró información en los documentos sobre este punto.	Destaca el uso de arquitecturas profundas y entrenamiento end-to-end (CTC) para superar redes feedforward.
Pascanu et al. (2013)	Evaluación empírica en predicción de música polifónica y modelado de lenguaje.	Análisis teórico de la profundidad en RNN (transiciones entrada-oculto, oculto-oculto y oculto-salida).	No se encontró información en los documentos sobre este punto.	Propone que la profundidad en las transiciones permite captar estructuras temporales complejas y altamente no lineales.
Cho et al. (2014)	Mejora del rendimiento en traducción estadística (SMT) medido por puntuaciones BLEU.	Análisis de representaciones semánticas y sintácticas aprendidas de frases lingüísticas.	No se encontró información en los documentos sobre este punto.	Introduce la arquitectura Encoder-Decoder y la unidad GRU para manejar secuencias de longitud variable.
Chung et al. (2014)	Comparación de LSTM, GRU y unidades tanh en modelado de música y señales de habla.	Discusión sobre mecanismos de compuerta y rutas de atajo para el flujo de gradientes.	No se encontró información en los documentos sobre este punto.	Concluye que las unidades con compuertas son superiores a las tradicionales para capturar dependencias de largo plazo.
Lipton et al. (2015)	Revisa benchmarks de clasificación de fonemas y tareas algorítmicas (copia, ordenamiento).	Revisión crítica de la historia, arquitecturas (LSTM, BRNN, NTM) y problemas de gradiente.	No se encontró información en los documentos sobre este punto.	Define a las RNN como modelos capaces de retener estados de una ventana de contexto arbitrariamente larga.
Salehinejad et al. (2018)	Reporta avances en el estado del arte para reconocimiento de escritura y habla.	Categorización sistemática de arquitecturas avanzadas (MDRNN, dRNN, MemNN) y regularización.	No se encontró información en los documentos sobre este punto.	Explica cómo los bucles de retroalimentación permiten a las RNN modelar sistemas dinámicos complejos.
Zhang et al. (2025)	Detección de comportamiento hasta 6 segundos antes del inicio; mejora estabilidad de gradientes.	Interpretación de mecanismos mediante valores SHAP y acumulación de evidencia en la decisión.	No se encontró información en los documentos sobre este punto.	Propone RNN de pesos variables (TV-RNN) para manejar cambios en la distribución temporal de datos neuronales.
Oruh et al. (2022)	Precisión del 99.36% en el conjunto de datos de dígitos hablados en inglés.	Incorporación de la RNN como 'compuerta de olvido' para resetear estados en sub-secuencias.	No se encontró información en los documentos sobre este punto.	Modifica la arquitectura LSTM para procesar flujos de entrada continuos de manera eficiente en ancho de banda.

Trabajo (Ref.)	Enfoque Cuantitativo	Enfoque Cualitativo	Enfoque Mixto	Observación
Rezk et al. (2020)	Mide rendimiento en OP/s y eficiencia energética en plataformas embebidas (FPGA, ASIC).	Discusión sobre optimizaciones algorítmicas como cuantización, poda y DeltaRNN.	No se encontró información en los documentos sobre este punto.	Analiza la viabilidad técnica de ejecutar modelos secuenciales pesados en dispositivos con recursos limitados.
Zhang et al. (2020)	Uso de métricas MSE, PSNR y SSIM para evaluar la extrapolación de muestras faltantes.	Estrategias para mitigar el desvanecimiento del gradiente mediante ELU y normalización por lotes.	No se encontró información en los documentos sobre este punto.	Aplica RNN optimizadas para el reconocimiento de secuencias HRRP de radar, mejorando la robustez al ruido.
Giannini et al. (2024)	Comparación mediante Cohen's Kappa y precisión balanceada en flujos de datos con deriva.	Fundamentación teórica sobre el olvido catastrófico y la adaptación rápida a nuevos conceptos.	No se encontró información en los documentos sobre este punto.	Propone DYNcPNN para gestionar dinámicamente derivas conceptuales en series temporales evolutivas.
Song et al. (2024)	Evaluación exhaustiva de MAE y MSE en pronóstico de series temporales multivariadas.	Revisión de dependencias entre pasos temporales y correlaciones entre variables.	No se encontró información en los documentos sobre este punto.	Analiza críticamente las limitaciones de las RNN (acumulación de errores) frente a modelos lineales y Transformers.
Zioviris et al. (2024)	Resultados de AUC de hasta 99.61% combinando autoencoders y LSTM para detección de fraude.	Estudio de patrones de conectividad neuronal para aprender atributos de distribución de datos.	No se encontró información en los documentos sobre este punto.	Utiliza LSTM para clasificar secuencias 'limpias' de características tras una reducción de dimensionalidad previa.

Bibliografía

- [1] A. Graves, A.-r. Mohamed y G. Hinton, "Speech recognition with deep recurrent neural networks," en Proc. IEEE Int. Conf. Acoust., Speech Signal Process. (ICASSP), Vancouver, BC, Canadá, 2013, pp. 6645-6649.
- [2] R. Pascanu, C. Gulcehre, K. Cho y Y. Bengio, "How to construct deep recurrent neural networks," arXiv preprint arXiv:1312.6026, 2013.
- [3] K. Cho et al., "Learning phrase representations using RNN encoder–decoder for statistical machine translation," en Proc. Conf. Empirical Methods Natural Lang. Process. (EMNLP), Doha, Qatar, 2014, pp. 1724-1734.
- [4] J. Chung, C. Gulcehre, K. Cho y Y. Bengio, "Empirical evaluation of gated recurrent neural networks on sequence modeling," arXiv preprint arXiv:1412.3555, 2014.
- [5] Z. C. Lipton, J. Berkowitz y C. Elkan, "A critical review of recurrent neural networks for sequence learning," arXiv preprint arXiv:1506.00019, 2015.
- [6] H. Salehinejad, S. Sankar, J. Barfett, E. Colak y S. Valaee, "Recent advances in recurrent neural networks," arXiv preprint arXiv:1801.01078, 2018.
- [7] Y. Zhang et al., "Behavioral classification of sequential neural activity using time varying recurrent neural networks," IEEE Transactions on Biomedical Engineering (Publicado online), 2025.
- [8] J. Oruh, S. Viriri y A. Adegun, "Long short-term memory recurrent neural network for automatic speech recognition," IEEE Access, vol. 10, pp. 31593-31549, 2022.
- [9] N. M. Rezk, M. Purnaprajna, T. Nordstrom y Z. Ul-Abdin, "Recurrent neural networks: An embedded computing perspective," IEEE Access, vol. 8, pp. 29824-29816, 2020.

- [10]** Y. Zhang, F. Xiao, F. Qian y X. Li, "VGM-RNN: HRRP sequence extrapolation and recognition based on a novel optimized RNN," IEEE Access, vol. 8, pp. 29860-29827, 2020.
- [11]** F. Giannini, G. Ziffer y E. Della Valle, "Dynamic continuous progressive neural networks for evolving streaming time series," Data Mining and Knowledge Discovery, 2024.
- [12]** X. Song et al., "Deep learning-based time series forecasting: A systematic review," Artificial Intelligence Review, vol. 57, no. 10989, 2024.
- [13]** G. Zioviris, K. Kolomvatsos y G. Stamoulis, "An intelligent sequential fraud detection model based on deep learning and oversampling," The Journal of Supercomputing, 2024.