

Información General del Estudiante

Nombre del estudiante: Emilio José Galvez Merchán

Técnica de IA: Redes Neuronal Recurrente (RNN)

Pregunta de investigación: ¿Qué papel juegan las RNN en el procesamiento de datos secuenciales?

Matriz de Extracción de Artículos Científicos: El papel de las RNN en el procesamiento secuencial

#	Referencia (IEEE)	Año	Base de datos	Técnica IA	Problema abordado	Objetivo del artículo	Metodología	Dataset / Contexto	Resultados principales	Limitaciones	Aporte para la PI
1	A. Graves, A.-r. Mohamed y G. Hinton, "Speech recognition with deep recurrent neural networks," en Proc. IEEE ICASSP, pp. 6645-6649, 2013. DOI: 10.1109/ICASSP.2013.6645649. Keywords: Speech recognition, deep recurrent neural networks.	2013	IEEE	Deep LSTM	El reconocimiento de fonemas enfrenta dificultades para capturar jerarquías de representación y dependencias a largo plazo simultáneamente. Las redes neuronales profundas (DNN) estándar no aprovechan la estructura temporal del habla de manera eficiente.	Evaluar el potencial de las redes LSTM profundas para el reconocimiento de voz de extremo a extremo. Demostrar que la profundidad arquitectónica mejora el rendimiento en tareas acústicas secuenciales.	Se diseñan arquitecturas de LSTM profundas apilando múltiples capas recurrentes. Se utiliza entrenamiento mediante Clasificación Temporal Conexiónista (CTC) para manejar datos no segmentados. Se aplica ruido de peso y parada temprana para regularización.	Corpus TIMIT, datos de audio codificados con bancos de filtros de 123 dimensiones.	Se logró un error de fonemas del 17.7% en el set de prueba de TIMIT, superando a las redes feedforward.	El entrenamiento es computacionalmente costoso y propenso al sobreajuste si no se regulariza adecuadamente.	Demuestra que las RNN profundas permiten captar niveles de abstracción jerárquica en señales temporales complejas. Proporciona una base para el procesamiento de voz moderno.
2	R. Pascanu, C. Gulcehre, K. Cho y Y. Bengio, "How to construct deep recurrent neural networks," arXiv preprint arXiv:1312.6026, 2013. Keywords: Deep RNN, depth ambiguity.	2013	arXiv	DT-RNN, DOT-RNN	El concepto de profundidad en las RNN es ambiguo debido a su naturaleza iterativa en el tiempo. Las transiciones estándar entre estados ocultos suelen ser superficiales, limitando la complejidad de las funciones que pueden modelar.	Proponer arquitecturas que introduzcan profundidad en las transiciones entrada-oculto, oculto-oculto y oculto-salida. Validar empíricamente que la profundidad mejora el modelado de secuencias.	Se introducen capas no lineales intermedias en las transiciones de estado para crear RNN de Transición Profunda (DT-RNN). Se proponen conexiones de salto (shortcuts) para facilitar el flujo de gradientes. Se evalúa el rendimiento en tareas de predicción de música y modelado de lenguaje.	Datasets de música polifónica (Nottingham, JSB Chorales) y modelado de lenguaje a nivel de palabra/carácter.	Las variantes profundas superaron consistentemente a las RNN superficiales en todos los benchmarks de predicción.	El entrenamiento de arquitecturas muy profundas (como DOT-RNN) es significativamente más difícil y requiere preentrenamiento.	Define que la capacidad de las RNN para procesar datos secuenciales depende de la profundidad de sus operadores de transición interna. Explica cómo manejar múltiples escalas de tiempo mediante el apilamiento de capas.
3	K. Cho et al., "Learning phrase representations using RNN encoder-decoder for statistical machine translation," en Proc. EMNLP, pp. 1724-1734, 2014. DOI: 10.3115/v1/D14-1179.	2014	ACL (Springer)	RNN Encoder-Decoder, GRU	La traducción estadística tradicional lucha por mapear frases de longitud variable en representaciones	Proponer una arquitectura Encoder-Decoder para aprender mapeos entre secuencias de	Un RNN (Encoder) mapea la entrada a un vector de longitud fija, y otro (Decoder) genera	Tarea de traducción Inglés-Francés del WMT'14 usando subconjuntos de	La inclusión de puntuaciones de la RNN mejoró el rendimiento de BLEU en sistemas de	Los modelos Encoder-Decoder de longitud fija pueden tener dificultades con oraciones	Establece el papel de las RNN como herramientas de comprensión de contexto secuencial en

#	Referencia (IEEE)	Año	Base de datos	Técnica IA	Problema abordado	Objetivo del artículo	Metodología	Dataset / Contexto	Resultados principales	Limitaciones	Aporte para la PI
	Keywords: SMT, GRU, Encoder-Decoder.				semánticas continuas. Las unidades recurrentes estándar no capturan dependencias de largo rango de forma efectiva.	longitud arbitraria. Introducir la Unidad Recurrente de Compuerta (GRU) para optimizar la memoria.	la secuencia objetivo. La GRU utiliza compuertas de reinicio y actualización para controlar el flujo de información. Se entrena el modelo para maximizar la probabilidad condicional de las secuencias.	datos de 348M de palabras.	traducción tradicionales.	extremadamente largas.	vectores de características. Introduce el mecanismo de compuertas adaptativas para diferentes escalas temporales.
4	J. Chung, C. Gulcehre, K. Cho y Y. Bengio, "Empirical evaluation of gated recurrent neural networks on sequence modeling," arXiv preprint arXiv:1412.3555, 2014. Keywords: Gated RNN, LSTM vs GRU.	2014	arXiv	LSTM, GRU	No está claro qué tipo de unidad recurrente con compuertas es superior para tareas generales de modelado secuencial. Las unidades recurrentes simples sufren de desvanecimiento de gradiente en secuencias largas.	Comparar empíricamente las unidades LSTM, GRU y tanh en tareas de modelado de música y habla. Determinar si la GRU es una alternativa viable y eficiente a la LSTM.	Se entrenan modelos con el mismo número de parámetros para garantizar una comparación justa. Se utiliza RMSProp y ruido de peso para el entrenamiento y optimización. Se evalúa la convergencia en tiempo de CPU y rendimiento de validación.	Datasets de música polifónica y señales de audio sin procesar de UbiSoft.	Las unidades con compuertas (LSTM/GRU) superaron ampliamente a las unidades tanh, especialmente en señales de voz. La GRU mostró convergencia más rápida en varios datasets.	Los resultados son preliminares y no permiten concluir una superioridad definitiva de una unidad sobre otra en todos los casos.	Confirma que las compuertas son esenciales para que las RNN capturen la estructura temporal de señales de alta dimensión. Provee evidencia sobre la eficiencia de las rutas de atajo temporales creadas por las sumas aditivas de las celdas.
5	Z. C. Lipton, J. Berkowitz y C. Elkan, "A critical review of recurrent neural networks for sequence learning," arXiv preprint arXiv:1506.00019, 2015. Keywords: Sequence learning, survey, LSTM.	2015	arXiv	RNN (Survey)	Existe una gran confusión en la literatura sobre la nomenclatura y aplicaciones de las RNN. Los modelos tradicionales de Markov son computacionalmente costosos para dependencias de largo rango.	Proveer una revisión crítica e intuitiva sobre el estado del arte de las RNN para el aprendizaje de secuencias. Sintetizar los avances en arquitecturas, algoritmos y aplicaciones prácticas.	Se realiza un análisis comparativo entre RNN, modelos de Markov y redes feedforward. Se revisan arquitecturas modernas como LSTM, BRNN y NTM. Se discuten técnicas de entrenamiento como BPTT y optimización de segundo orden.	Revisión de literatura histórica (1980s) hasta aplicaciones modernas como subtítulos de imágenes y traducción.	Concluye que las RNN han pasado de ser modelos de interés biológico a herramientas prácticas escalables gracias a las GPU.	El entrenamiento de RNN sigue siendo un desafío de optimización NP-completo en su forma básica.	Define a las RNN como modelos conexionistas con ciclos que capturan la dinámica de secuencias integrando el tiempo. Explica que las RNN rompen el supuesto de independencia entre ejemplos, permitiendo el flujo de información a través de pasos temporales.
6	H. Salehinejad et al., "Recent advances in recurrent neural networks," arXiv preprint arXiv:1801.01078, 2018. Keywords: Deep learning, long-term dependency, time-series.	2018	arXiv (Survey)	RNN, MDRNN, RCNN	Las RNN tradicionales enfrentan inestabilidad en el aprendizaje de dependencias a largo plazo. El procesamiento de datos multidimensionales requiere ir más allá de las cadenas	Presentar un estudio exhaustivo sobre los avances recientes en arquitecturas de RNN. Identificar los desafíos de investigación actuales y las soluciones propuestas.	Se categorizan las RNN en modelos profundos, bidireccionales, convolucionales (RCNN) y multidimensionales (MDRNN). Se analizan métodos de entrenamiento como EKF, Hessian-free y algoritmos	Revisión sistemática de arquitecturas desde la red de Elman (1990) hasta unidades ortogonales de compuerta (2017).	Destaca que los mecanismos de compuerta han sido el avance clave para que las RNN modelen sistemas dinámicos no lineales complejos.	El costo computacional de las capas adicionales y la dificultad de paralelizar el paso temporal siguen siendo cuellos de botella.	Sistematiza el papel de las RNN en el modelado de dependencias espaciotemporales en medicina, video y visión. Explica cómo la recurrencia permite suavizar salidas basándose en el historial.

#	Referencia (IEEE)	Año	Base de datos	Técnica IA	Problema abordado	Objetivo del artículo	Metodología	Dataset / Contexto	Resultados principales	Limitaciones	Aporte para la PI
					secuenciales unidimensionales.		evolutivos. Se discuten mecanismos de regularización como el dropout recurrente.				
7	G. Di Gennaro et al., "A General Framework for Scalable UE-AP Association in User-Centric Cell-Free Massive MIMO Based on RNN," Preprint, 2024. Keywords: BiLSTM, Massive MIMO, AP association.	2024	IEEE (Workshop)	BiLSTM	La asociación dinámica entre usuarios (UE) y puntos de acceso (AP) en sistemas MIMO masivos es un problema de optimización complejo. Los métodos heurísticos no se adaptan bien a condiciones cambiantes del canal.	Desarrollar un marco escalable basado en BiLSTM para la asociación UE-AP. Optimizar métricas de eficiencia espectral en entornos con y sin contaminación de pilotos.	Se utiliza una red BiLSTM para procesar secuencias de AP ordenadas consistentemente. Se implementa una arquitectura con capas FC para la clasificación final de enlaces. Se proponen enfoques escalables mediante limitación del dominio de conectividad local.	Entorno simulado de 700x700 m² con 25-49 APs y configuraciones variables de usuarios.	El método BiLSTM superó consistentemente a los baselines de LSFC en suma de SE y equidad.	El rendimiento depende críticamente de establecer un orden consistente en la secuencia de entrada de los AP.	Utiliza las RNN para generalizar problemas de agrupamiento espacial como tareas de procesamiento de secuencias. Aprovecha la naturaleza bidireccional para modelar el contexto espacial en ambas direcciones de la red.
8	Y. Zhang et al., "Behavioral Classification of Sequential Neural Activity Using Time Varying Recurrent Neural Networks," IEEE Trans. Biomed. Eng., 2025. DOI: 10.1109/TNSRE.2025.3586175. Keywords: TV-RNN, neural activity.	2025	IEEE	TV-RNN	Los cambios en la distribución de datos a lo largo del tiempo dificultan la clasificación temprana en series temporales neuronales. Las RNN estándar no pueden adaptarse a estas variaciones temporales.	Proponer RNN con pesos variables en el tiempo (TV-RNN) para mejorar la clasificación temprana de actividad neuronal. Evaluar la estabilidad de los gradientes y la interpretabilidad.	Se implementa una RNN donde los pesos cambian en cada ventana temporal. Se utiliza BPTT y valores SHAP para interpretar la contribución de las regiones cerebrales. Se compara con Transformers y RNN estándar en tareas motoras.	Datos de ratones (WFCI) y humanos (fMRI) durante tareas de tracción de palanca y fuerza de agarre.	Las TV-RNN detectaron el comportamiento hasta 6 segundos antes de su inicio, 3 segundos antes que las RNN estándar.	Los modelos de alta dimensión pueden carecer de interpretabilidad; se prefieren modelos de baja dimensión en este estudio.	Muestra que las RNN pueden adaptarse a derivas en la distribución de datos secuenciales mediante pesos dinámicos. Confirma que el procesamiento recurrente permite la acumulación de evidencia para decisiones tempranas.
9	J. Oruh, S. Viriri y A. Adegun, "Long short-term memory recurrent neural network for automatic speech recognition," IEEE Access, vol. 10, pp. 31593-31549, 2022. DOI: 10.1109/ACCESS.2022.3159349 . Keywords: LSTM, Speech recognition.	2022	IEEE	LSTM, RNN como compuerta	El reconocimiento de voz en entornos con ruido requiere ventanas contextuales dinámicas que las redes feedforward no poseen. El entrenamiento de RNN puras es difícil por el desvanecimiento de gradiente.	Proponer una modificación de la arquitectura LSTM donde se integra una RNN como compuerta de olvido. Mejorar la precisión del reconocimiento de dígitos hablados en inglés.	Se ajusta la arquitectura LSTM añadiendo conexiones de retroalimentación en la compuerta de olvido. Se utiliza preprocesamiento de audio con librosa y generadores de batches MFCC. El modelo se entrena con TFLearn variando la tasa de aprendizaje.	Dataset Pannous de dígitos hablados (0-9) por 15 hablantes, totalizando 2400 archivos de audio.	Se obtuvo una precisión de validación máxima del 99.36% ajustando la tasa de aprendizaje y las iteraciones.	La modificación de la arquitectura incrementa el costo computacional debido a la adición de recursos para la nueva compuerta.	Refuerza el papel de las RNN en el almacenamiento de entradas por períodos prolongados para situaciones temporales extendidas. Valida que las variantes de RNN son superiores para capturar patrones de habla comparadas con modelos HMM híbridos.
10	A. Siebert et al., "Low-Complexity and Low-Energy	2026	IEEE	GRU, SKF	La estimación de canales	Diseñar un Filtro de Kalman	Se emplean dos redes: una GRU	Dataset de 2 millones de	La implementación	Superar un umbral de 128 unidades en	Sitúa a las RNN (GRU) como

#	Referencia (IEEE)	Año	Base de datos	Técnica IA	Problema abordado	Objetivo del artículo	Metodología	Dataset / Contexto	Resultados principales	Limitaciones	Aporte para la PI
	RNN-Enhanced Kalman Filter for Channel Estimation: A Case Study," IEEE OJCOMS, 2026. DOI: 10.1109/OJCOMS.2026.3665311. Keywords: Channel estimation, Kalman filter, GRU.				inalámbricos en entornos militares de alta movilidad presenta variaciones abruptas de Doppler. Los filtros de Kalman tradicionales tienen dificultades para adaptar sus parámetros de ruido en tiempo real.	Inteligente (SKF) que utilice RNN para estimar dinámicamente las matrices de covarianza Q y R. Optimizar la complejidad para su ejecución en plataformas FPGA y CPU de baja potencia.	(NN1) para la matriz Q y una red FC (NN2) para la matriz R. Se realiza un estudio de compensación rendimiento-complejidad. Se implementan modelos en punto fijo para reducir el consumo energético en hardware.	canales con variaciones de Doppler entre 10^{-3} y 10^{-1} .	en FPGA Virtex-7 alcanzó 20.54 Mbps con un consumo de 2.5 nJ por bit.	la capa GRU no mejora el rendimiento y solo aumenta la complejidad.	estimadores de parámetros de sistemas dinámicos en paralelo a filtros clásicos. Demuestra su viabilidad en aplicaciones de baja latencia y alta eficiencia energética.
1 1	N. M. Rezk et al., "Recurrent Neural Networks: An Embedded Computing Perspective," IEEE Access, vol. 8, 2020. DOI: 10.1109/ACCESS.2020.2982416. Keywords: Compression, embedded computing, LSTM, quantization.	2020	IEEE	LSTM, GRU (Survey)	Ejecutar RNN en dispositivos embebidos es difícil por sus altos requerimientos de cómputo y memoria. La dependencia temporal impide la paralelización masiva que se logra en las CNN.	Revisar las implementaciones existentes de RNN en plataformas embebidas y discutir métodos para superar limitaciones de hardware. Proponer directrices para diseñadores de hardware.	Se analizan componentes de RNN desde la perspectiva de arquitectura de computadoras. Se revisan optimizaciones como cuantización, poda y matrices circulares. Se evalúa la eficiencia de implementaciones en FPGA, ASIC y GPU móviles.	Comparativa sistemática de múltiples trabajos usando datasets como TIMIT, Penn Treebank y MNIST.	Identifica que el uso de matrices circulares y cuantización de baja precisión (hasta 1 bit) son las técnicas más efectivas para alta eficiencia.	Las optimizaciones agresivas pueden reducir la precisión del modelo por debajo de los límites aceptables de la aplicación.	Explica el papel de las RNN como modelos que añaden retroalimentación para funcionar de forma similar a la memoria humana. Detalla cómo las variantes como DeltaRNN reducen cálculos al explotar la correlación temporal entre entradas sucesivas.
1 2	Y. Zhang et al., "VGM-RNN: HRRP sequence extrapolation and recognition based on a novel optimized RNN," IEEE Access, vol. 8, pp. 70071-70081, 2020. DOI: 10.1109/ACCESS.2020.2986027. Keywords: VGM-RNN, HRRP, radar recognition.	2020	IEEE	VGM-RNN (Optimized RNN)	El reconocimiento de objetivos mediante secuencias HRRP de radar falla cuando faltan muestras. Las RNN clásicas sufren de desvanecimiento de gradiente en secuencias largas.	Proponer un modelo RNN optimizado (VGM-RNN) para la extrapolación y reconocimiento de secuencias HRRP incompletas. Introducir estrategias como la función ELU y BN para mitigar problemas de gradiente.	Se utiliza una arquitectura de dos pasos: extrapolación de datos perdidos y luego reconocimiento. Se implementa un algoritmo de levantamiento de gradiente. Se comparan resultados con modelos HMM y RTRBM.	Dataset MSTAR con objetivos T-72, BMP-2 y BTR-70, simulando un 20% de muestras perdidas.	Se logró una precisión de reconocimiento del 95.07%, superando a la RNN clásica (93.52%) y modelos basados en promedio.	El modelo asume longitudes de secuencia fijas; la gestión de longitudes variables es un tema de investigación futura.	Define el papel de las RNN en la reconstrucción de señales espaciotemporales mediante correlaciones históricas. Valida que las mejoras en funciones de activación permiten a las RNN procesar secuencias de alta dimensión con mayor estabilidad.
1 3	H. Honda y M. Hagiwara, "Efficient unification using memory networks and recurrent neural networks," Neural Computing and Applications, 2025. DOI: 10.1007/s00521-025-11512-y. Keywords: Neuro-symbolic AI, DNC, Seq2Seq.	2025	Springer	DNC, Seq2Seq (RNN)	El procesamiento simbólico convencional no maneja bien datos ambiguos, mientras que las redes neuronales puras tienen dificultades con el razonamiento lógico complejo. Las RNN estándar tienen memoria limitada	Proponer una red que realice unificación combinando redes de memoria y RNN. Manejar grandes bases de conocimiento con datos ruidosos o palabras desconocidas.	Se utiliza una Computadora Neuronal Diferenciable (DNC) para el emparejamiento de hechos. Se emplea una arquitectura Seq2Seq con atención para la sustitución de variables. Se	Datasets de relaciones familiares (Kinsources) y base de datos de películas IMDb.	El método logró una tasa de respuestas correctas superior al 0.99 para palabras conocidas y desconocidas en condiciones de big data.	El tiempo de ejecución para redes de sustitución es significativamente mayor que para las redes de emparejamiento.	Muestra cómo las RNN integradas en sistemas neuro-simbólicos pueden realizar síntesis de programas y razonamiento deductivo. Valida el papel de los mecanismos de atención en RNN para procesar

#	Referencia (IEEE)	Año	Base de datos	Técnica IA	Problema abordado	Objetivo del artículo	Metodología	Dataset / Contexto	Resultados principales	Limitaciones	Aporte para la PI
					dependiente del número de neuronas.		implementa un preprocesador para convertir nombres propios en átomos procesables.				estructuras de datos complejas.
14	X. Song et al., "Deep learning-based time series forecasting: A systematic review," Artificial Intelligence Review, vol. 57, no. 10989, 2024. DOI: 10.1007/s10462-024-10989-8. Keywords: Time series forecasting, RNN, MAE/MSE.	2024	Springer	RNN, LSTM, Transformer	El pronóstico de series temporales enfrenta problemas de desvanecimiento de gradiente y acumulación de errores en predicciones de múltiples pasos. Muchos modelos complejos sufren de sobreajuste y son sensibles al ruido.	Realizar una revisión sistemática de la evolución de modelos de pronóstico desde 2014 hasta 2024. Evaluar la efectividad de algoritmos en tareas univariadas y multivariadas en diversos dominios.	Se analizan capacidades de minería de información (correlación entre pasos de tiempo vs entre variables). Se realizan experimentos de barajado y extensión de ventana para medir sobreajuste. Se comparan baselines estadísticos (ARIMA) con modelos de aprendizaje profundo.	Datasets ETT, Electricity, Traffic, Exchange e ILI (gripe) de 4 dominios distintos.	Los modelos basados en parches (PatchTST) y modelos lineales simples superaron a arquitecturas RNN/Transformer complejas en varios benchmarks.	El rendimiento de los modelos basados en RNN decae al aumentar los pasos de tiempo de pronóstico.	Explica que el papel de las RNN es encapsular atributos temporales permitiendo que las características previas actúen como entradas actuales. Discute cómo los mecanismos de celdas y estados en RNN mitigan el ruido en datos históricos.
15	F. Giannini, G. Ziffer y E. Della Valle, "Dynamic continuous progressive neural networks for evolving streaming time series," Data Mining and Knowledge Discovery, 2024. DOI: 10.1007/s10618-026-01213-y. Keywords: Streaming Continual Learning, cPNN, LSTM.	2024	Springer	DYNcPNN (LSTM)	Los flujos de datos continuos sufren de deriva conceptual (concept drift) que causan olvido catastrófico. Las soluciones SCL deben adaptarse sin conocer los timestamps de las derivas de antemano.	Extender las capacidades de las PNN para servir como solución efectiva de aprendizaje continuo en flujos de datos. Evitar el crecimiento arquitectónico innecesario mediante decisiones dinámicas.	Se combina la arquitectura cPNN con un detector de deriva conceptual (Sentinel). Se utilizan columnas de LSTM que se congelan o añaden según la severidad de la deriva. Se implementa un integrador dinámico de columnas (DCI) para gestionar un pool de modelos.	Datasets sintéticos (SRWM) y reales de calidad de aire, consumo de energía y clima (Weather).	DYNcPNN se adaptó más rápido a derivas y redujo significativamente el uso de memoria comparado con cPNN estándar.	La parametrización empírica puede no ser óptima y requiere sintonización de hiperparámetros en tiempo real.	Define el papel de las RNN (LSTM) como bloques de construcción en arquitecturas progresivas que aíslan y reutilizan conocimientos de cada concepto temporal. Establece que las celdas de memoria son vitales para la dependencia temporal en flujos masivos.
16	G. Zioviris, K. Kolomvatsos y G. Stamoulis, "An intelligent sequential fraud detection model based on deep learning and oversampling," The Journal of Supercomputing, 2024. DOI: 10.1007/s11227-024-06030-y. Keywords: Fraud detection, Autoencoders, LSTM, SMOTE.	2024	Springer	AE/VAE + LSTM	La detección de fraude financiero enfrenta datasets altamente desbalanceados y la necesidad de identificar patrones en múltiples dimensiones. Los eventos fraudulentos pueden afectar gravemente la reputación de las instituciones.	Proponer un esquema secuencial que combine autoencoders con redes LSTM para la detección de fraudes. Evaluar el impacto de técnicas de sobremuestreo (SMOTE, ADASYN) en el rendimiento.	Se utiliza un autoencoder (Simple o Variacional) para reducción de dimensionalidad y limpieza de características. La capa oculta del autoencoder alimenta a una LSTM para la clasificación final. Se aplica validación estratificada de 5 pliegues.	Dataset BankSim de interacciones financieras disponible en Kaggle.	Se obtuvieron valores de AUC de hasta 99.61% usando K-Means SMOTE y Autoencoder Simple con LSTM.	El estudio aún no incorpora completamente el eje temporal y la estacionalidad de los eventos de fraude.	Asigna a las LSTM el papel de clasificador final de secuencias limpias, aprendiendo atributos de distribución tras la reducción de datos. Valida que los patrones de conectividad de las RNN son superiores a las CNN para esta tarea.

#	Referencia (IEEE)	Año	Base de datos	Técnica IA	Problema abordado	Objetivo del artículo	Metodología	Dataset / Contexto	Resultados principales	Limitaciones	Aporte para la PI
17	M. Krok, W. P. HuneK y D. Horla, "Application of feedforward and recurrent neural networks in intelligent and predictive control systems," Control Theory and Technology, 2024. DOI: 10.1007/s11768-024-00234-6. Keywords: GPC, RNN, nonlinear systems.	2024	Springer	RNN, RBF	Los controladores predictivos generalizados (GPC) tradicionales tienen altos costos computacionales al resolver problemas de optimización en tiempo real para sistemas no lineales. Las aproximaciones linealizadas tienen desventajas en precisión.	Evaluar si una red neuronal puede gobernar un escenario de control basándose en variables de proceso observadas. Proponer un método basado en RNN para controladores GPC.	Se diseña una RNN para aprender la dependencia entre variables de proceso y señales de control. Se utiliza una red de base radial (RBF) para predecir la respuesta del sistema no lineal. Se realizan simulaciones bajo parámetros variables para garantizar la generalización.	Datos generados de simulaciones de leyes de control bajo diferentes setpoints y condiciones iniciales.	El enfoque basado en ANN permitió limitar significativamente el esfuerzo computacional en estrategias de control complejas.	La selección cuidadosa de hiperparámetros y funciones de activación es crítica para el éxito del experimento.	Destaca el papel de las RNN en la comprensión intrínseca de algoritmos de control, permitiendo ajustar operaciones a índices de rendimiento. Valida su uso para obtener muestras de control óptimas en tiempo real.
18	P. Frazzetto et al., "Graph Neural Networks for Candidate-Job Matching: An Inductive Learning Approach," Data Science and Engineering, 2025. DOI: 10.1007/s41019-025-00293-y. Keywords: CJM, GNN, LLM.	2025	Springer	GNN (vs MLP/RNN)	El emparejamiento candidato-puesto (CJM) sufre de un desbalance de clases extremo (95% de rechazo) y datos multimodales complejos. Las representaciones basadas solo en vectores omiten las relaciones semánticas entre entidades.	Desarrollar un marco de representación basado en grafos que modele explícitamente las relaciones entre candidatos y empleos. Validar la eficacia de las GNN frente a métodos tradicionales.	Se construyen grafos bipartitos usando LLMs (GPT-4) para extraer entidades y embeddings. Se evalúan cinco arquitecturas GNN contra baselines de perceptrón multicapa. Se utiliza optimización bayesiana con Optuna para los hiperparámetros.	Datos de 62 procesos de selección reales con 8360 candidatos y 9532 aplicaciones.	GCN logró una precisión balanceada del 65.4%, identificando al 48.9% de los candidatos calificados frente al 8.5% del baseline.	Los modelos todavía tienen dificultades con la clasificación ordinal de las etapas de reclutamiento.	Sitúa a las arquitecturas secuenciales como la base sobre la cual los modelos relacionales deben construir. Menciona que el modelado explícito de relaciones es una extensión necesaria de los modelos de secuencias tradicionales.
19	Z. Che et al., "Recurrent Neural Networks for Multivariate Time Series with Missing Values," Scientific Reports, vol. 8, no. 6085, 2018. DOI: 10.1038/s41598-018-24271-9. Keywords: Multivariate time series, missing values, GRU-D.	2018	Nature (Springer)	GRU-D	Los datos de series temporales en salud suelen tener muchos valores faltantes correlacionados con las etiquetas objetivo. Los métodos de imputación simples no manejan bien longitudes variables ni patrones de ausencia informativos.	Desarrollar el modelo GRU-D que incorpore patrones de ausencia (masking e intervalos) directamente en la arquitectura. Mejorar el rendimiento en series temporales multivariadas incompletas.	Se modifica la arquitectura GRU para incluir capaces términos de decaimiento (decay) para las entradas y estados ocultos. Los decaimientos son entrenables y dependen del tiempo transcurrido desde la última observación. Se compara con baselines de imputación forward y media.	Datasets clínicos MIMIC-III (ICU) y PhysioNet, con tareas de predicción de mortalidad y diagnóstico.	GRU-D superó a todos los baselines RNN y no-RNN en términos de AUC, demostrando escalabilidad con el tamaño de los datos.	El comportamiento ante datos que no faltan de forma aleatoria (MNAR) requiere más análisis teórico.	Establece el papel de las RNN como modelos de capturar no solo la dinámica de la señal, sino también la dinámica de la observación a través de pesos decadentes en el tiempo.
20	Daimler Truck Research Group, "Multi-Object Tracking Framework using SPENT, SANT and MANTa," Preprint, 2026. DOI: 10.1007/s43684-026-00127-2. Keywords: Multi-Object Tracking, TbD, LSTM.	2026	Springer	LSTM, BiLSTM, GRU	El seguimiento de múltiples objetos (MOT) en vehículos autónomos requiere predicción de estados y asociación de datos	Desarrollar tres redes neuronales (SPENT, SANT, MANTa) para predicción y asociación de objetos en un	SPENT (LSTM) reemplaza el modelo de movimiento del filtro de Kalman para predecir estados. MANTa	Dataset KITTI con objetos reales (autos y camionetas) en escenarios de tráfico.	SPENT redujo el RMSE vs modelos de movimiento clásicos; MANTa procesó asociaciones	La validación se limita actualmente al dataset KITTI; se requiere probar la transferencia a otras	Define a las RNN (LSTM y BiLSTM) como reemplazos de modelos físicos cinemáticos para capturar

#	Referencia (IEEE)	Año	Base de datos	Técnica IA	Problema abordado	Objetivo del artículo	Metodología	Dataset / Contexto	Resultados principales	Limitaciones	Aporte para la PI
					en tiempo real bajo incertidumbre. Los métodos tradicionales fallan al manejar escenarios complejos de múltiples entradas y salidas de sensores.	flujo de detección. Optimizar la inferencia para sistemas embebidos en tiempo real.	(BiLSTM) realiza asociaciones conjuntas de múltiples mediciones a múltiples trayectorias. Se utiliza pre-padding y ordenamiento de secuencias para optimizar el entrenamiento.		múltiples en solo 3.5 ms.	configuraciones de sensores.	dinámicas de objetos complejas. Valida que las RNN pueden resolver problemas combinatorios de asociación de datos de manera más eficiente que algoritmos manuales.

Síntesis

El análisis transversal de los documentos revela una evolución metodológica clara desde las RNN simples hasta arquitecturas de compuertas especializadas como LSTM y GRU, las cuales han resuelto el problema crítico del desvanecimiento del gradiente. Se identifica una tendencia hacia el aumento de la profundidad arquitectónica en las transiciones de estado, permitiendo que las redes capturen dinámicas temporales con niveles jerárquicos de abstracción similares a las redes feedforward pero aplicados al tiempo. Paralelamente, surge una rama de investigación enfocada en la eficiencia computacional para sistemas embebidos, donde técnicas de cuantización, poda y optimización de acceso a memoria son vitales para aplicaciones de baja latencia como vehículos autónomos y comunicaciones móviles. Trade-offs comunes incluyen la complejidad de entrenamiento frente a la capacidad de memoria, y la necesidad de regularización para evitar el sobreajuste en secuencias con ruido. Finalmente, se observa la integración de RNN con otros paradigmas como el aprendizaje continuo y el procesamiento simbólico, permitiendo que los modelos manejen derivas de datos (concept drift) y realicen razonamientos lógicos complejos.

Respuesta a la Pregunta de Investigación

¿Qué papel juegan las RNN en el procesamiento de datos secuenciales?

Las RNN actúan como sistemas dinámicos adaptativos que rompen el supuesto de independencia entre datos, permitiendo que la información fluya y se transforme a través de pasos temporales sucesivos. Su papel fundamental es actuar como una memoria distribuida de contexto arbitrariamente largo, capaz de comprimir secuencias de longitud variable en representaciones de estado interno que facilitan la predicción, clasificación y generación de datos. Además, sirven como interpoladores de información perdida y capturadores de dinámicas no lineales complejas, superando las limitaciones de los modelos físicos cinemáticos y estadísticos de Markov. En el ecosistema moderno de IA, las RNN funcionan como bloques de construcción versátiles que, al integrarse con mecanismos de atención o compuertas, permiten modelar desde señales biológicas sutiles hasta flujos masivos de datos en tiempo real.